Système de question-réponse sur la documentation Git

BENADDI Hafssa · Dr BELFROUH Sanae · 28-10-2026

SDIA 2026-2027 ENSAJ

Problème et objectif

Trouver une réponse précise sans lire toute la documentation

PROBLÈME

Question de l'utilisateur

Which tool is an alternative to git-filter-branch that avoids its performance problems?



?

Documentation Git

70 pages · 2 303 passages

Lire et chercher à la main :
lent, et on peut rater la bonne ligne

OBJECTIF

Même question

Which tool is an alternative to git-filter-branch that avoids its performance problems?

Système de question-réponse

Retriever
BM25 · 5 meilleurs passages

Reader
RoBERTa (SQuAD 2.0)

Réponse courte + passage source

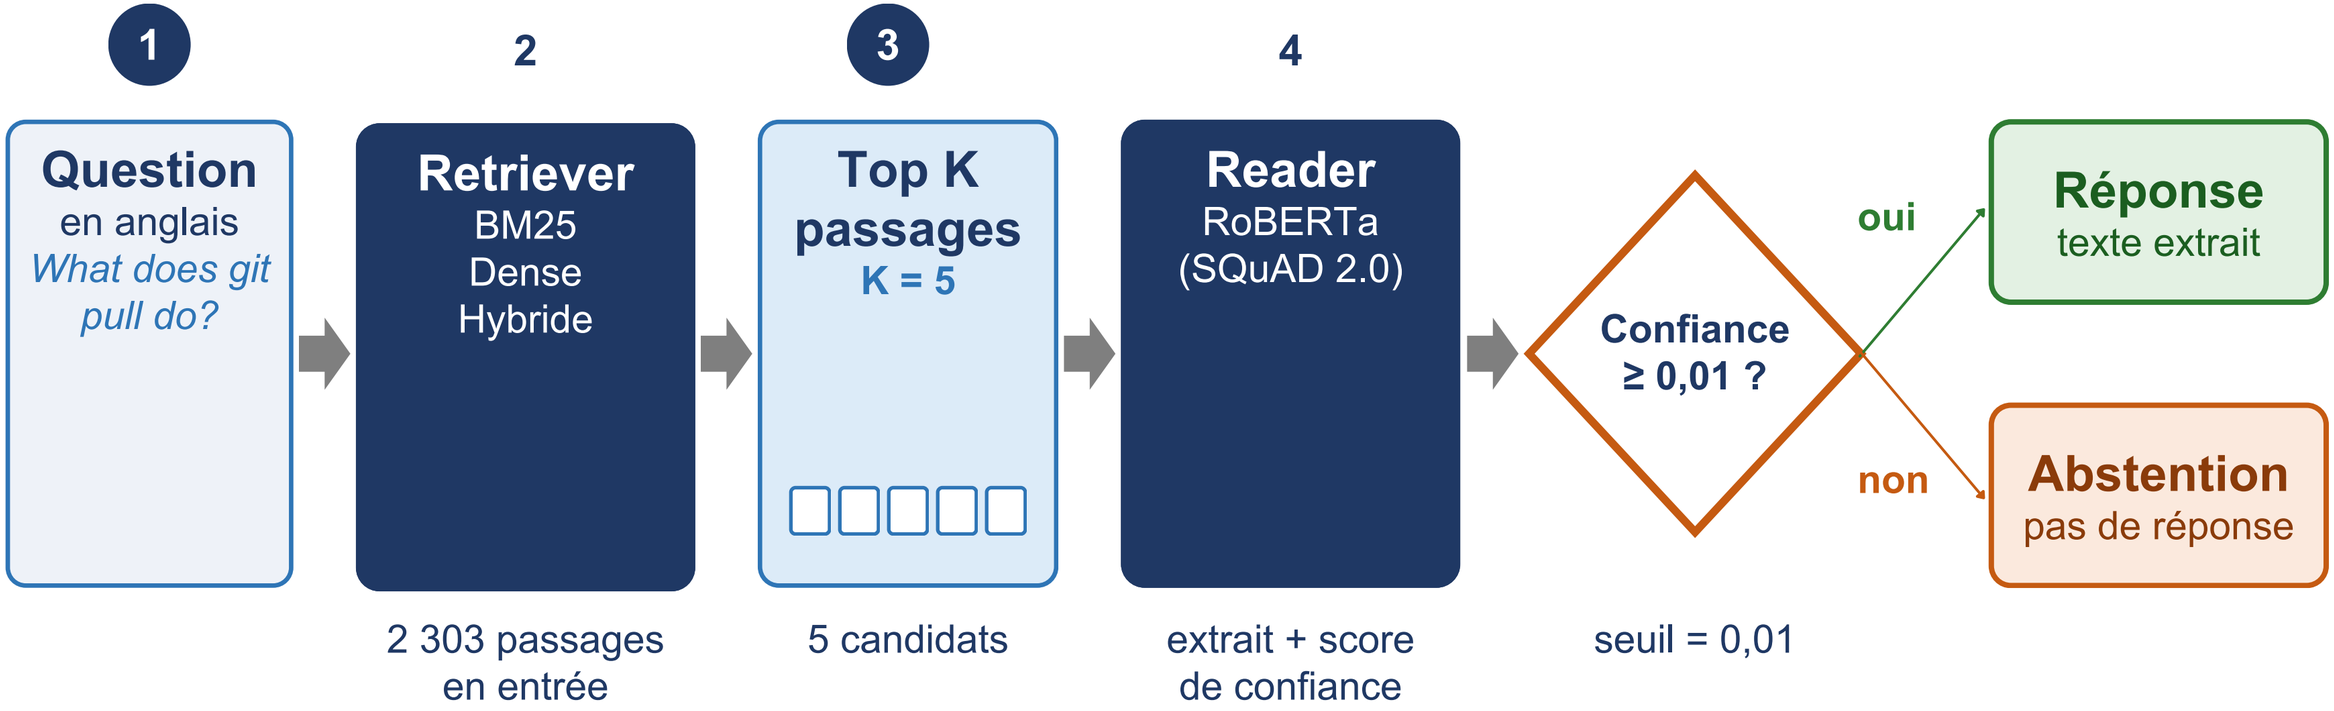
`git filter-repo`

Source : git-filter-branch (git-scm.com/docs)

Une réponse précise, avec sa source,
sans lire toute la documentation

Exemple tiré du jeu de test (réponse attendue : git filter-repo)

Architecture du système



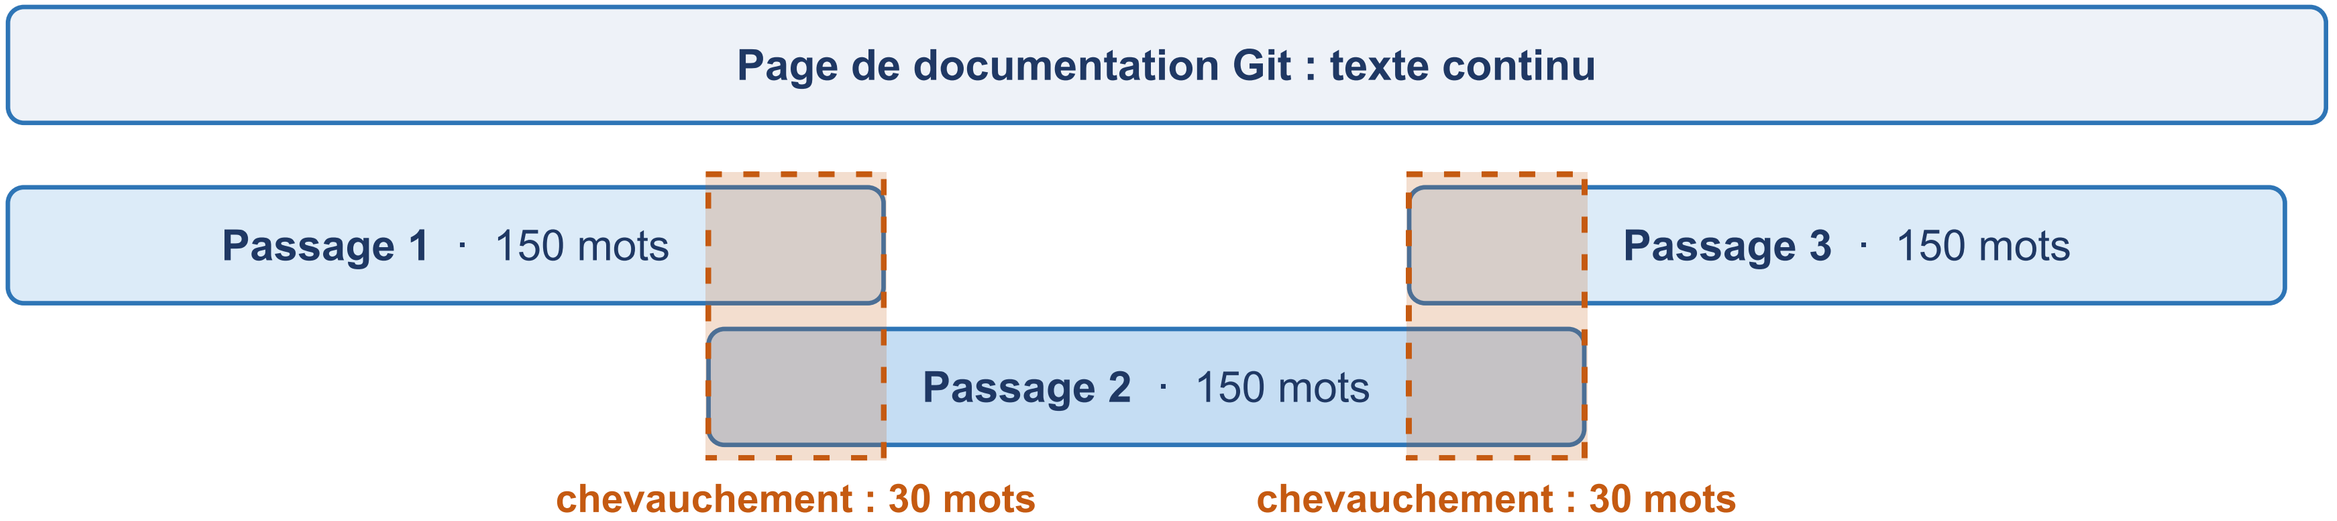
Le retriever réduit 2 303 passages à 5 candidats ; le Reader en extrait la réponse.

Dataset : documentation Git

70	677	482 / 195	51
documents	paires question-réponse	dev / test	documents couverts

- Source : pages de commandes de git-scm.com/docs
- Questions générées par un LLM, puis audit automatique (716 → 677 paires)
- Format SQuAD : question, contexte, réponse, position de la réponse
- Séparation dev / test par document, pour éviter toute fuite

Prétraitement : segmentation en passages



Le chevauchement évite de couper une réponse entre deux passages.

70
pages

segmentation
150 mots

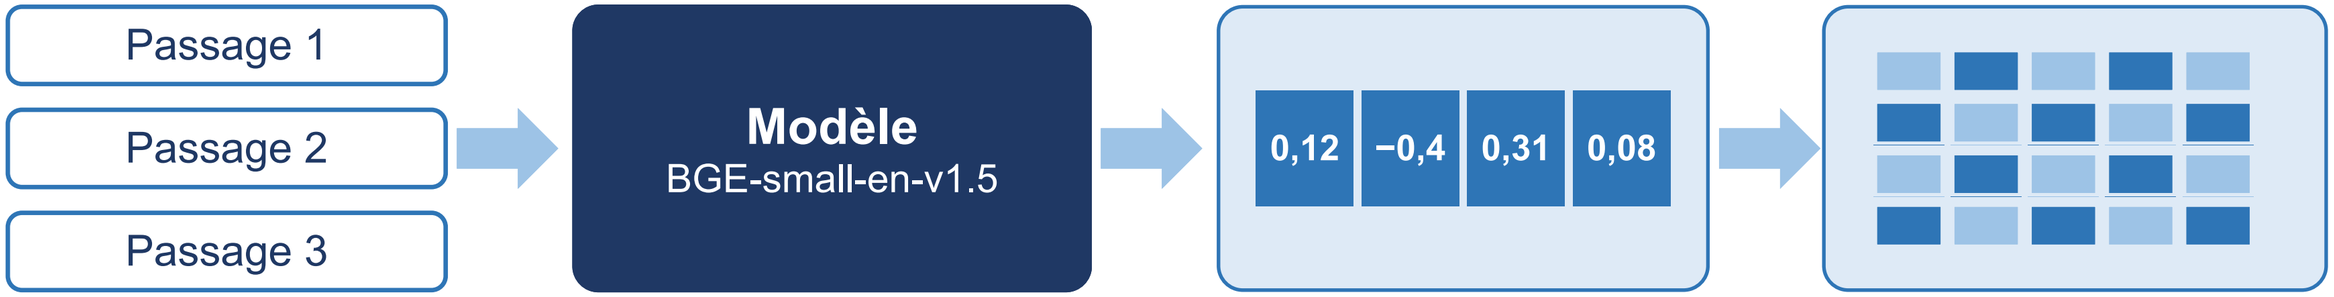
2 505
passages produits

nettoyage
− 196 menus
− 6 doublons

2 303
passages (final)

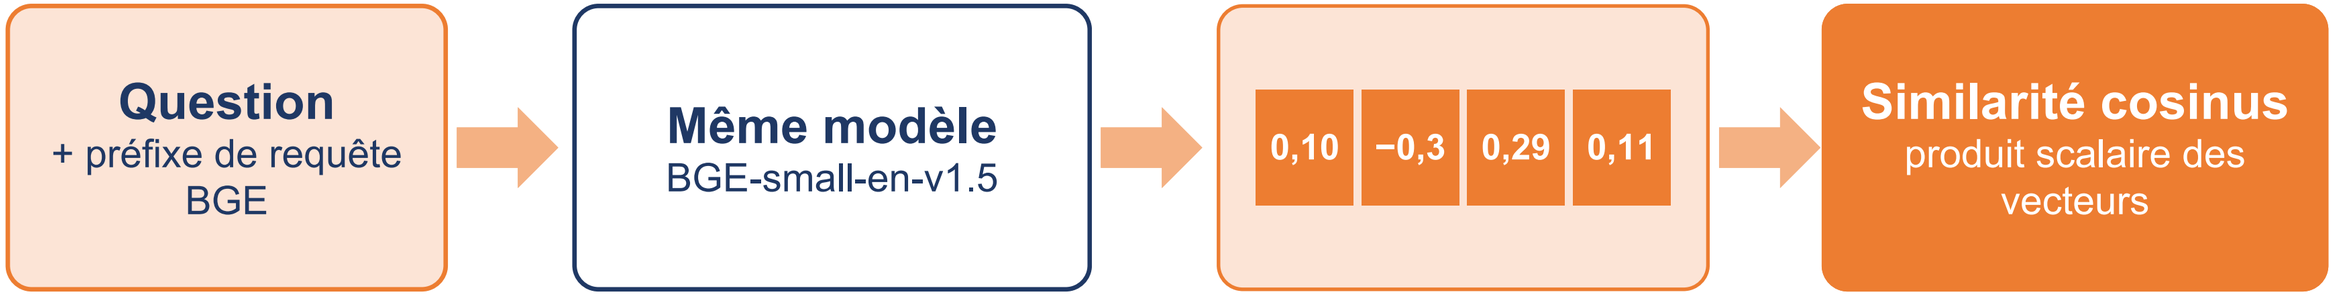
Représentation : embeddings

1 Indexation des passages (faite une seule fois)



Textes du document — Texte → nombres — Vecteur : 384 nombres, norme 1 — Matrice (.npy), réutilisée

2 Recherche à partir d'une question



Idée clé : deux textes de sens proche ont des vecteurs proches

Modélisation : retriever et Reader

Question

Retriever

Trouve les passages utiles

- **BM25 : mots-clés**
- **Dense : embeddings**
- **Hybride : fusion des classements**

Passage 1

Passage 2

Passage 3

Meilleurs passages

Reader

deepset/roberta-base-squad2



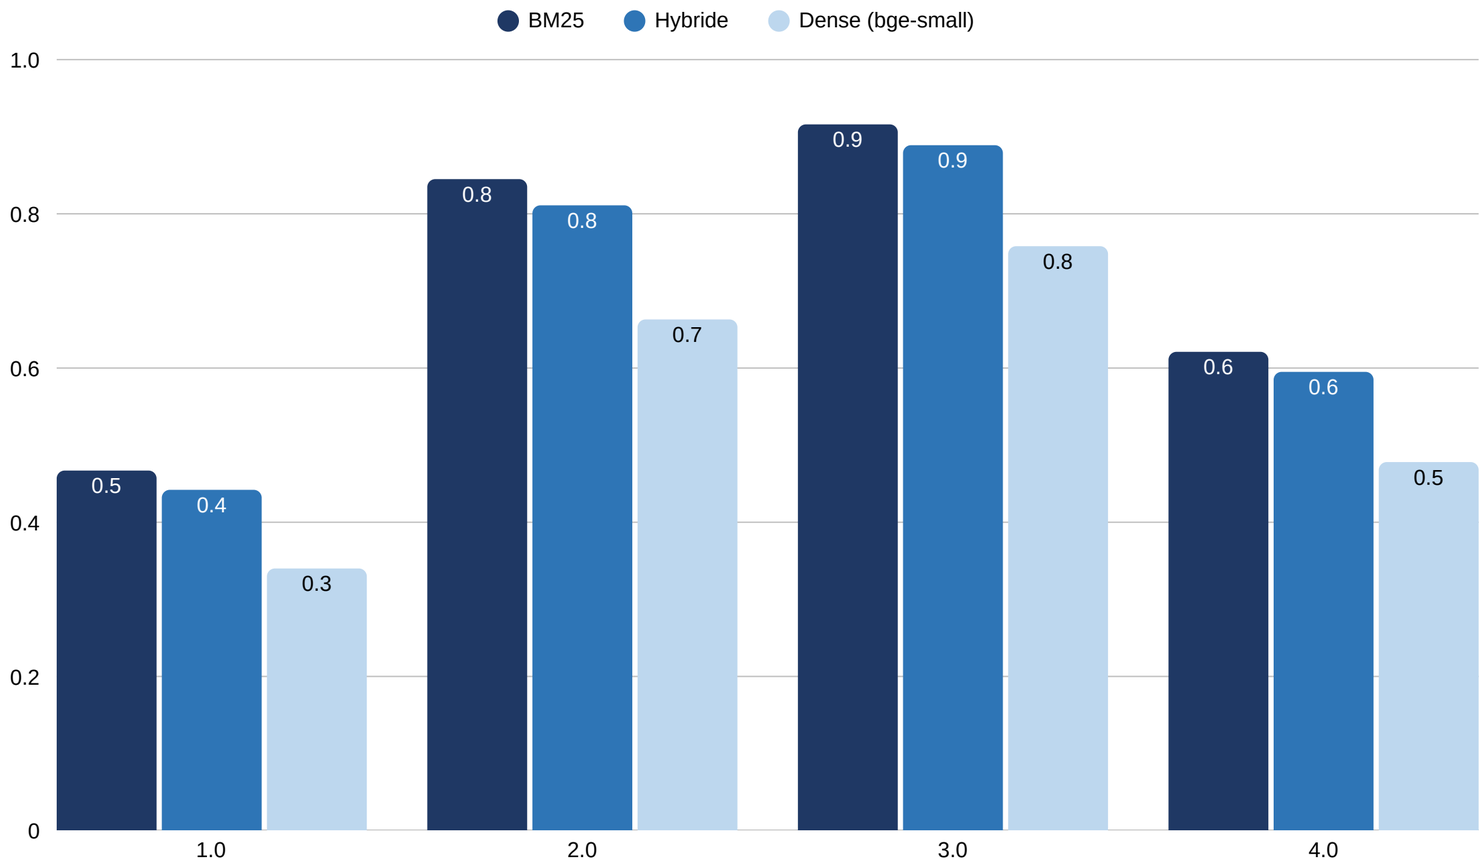
Extrait la réponse du texte

Seuil de confiance : 0,01 (réglé sur les questions dev + 20 questions hors sujet)

Score ≥ 0,01 : la réponse est affichée

Score < 0,01 : « pas de réponse »

Évaluation du retriever (677 questions)



Mode strict

Le passage de référence est dans les K premiers

Mode souple

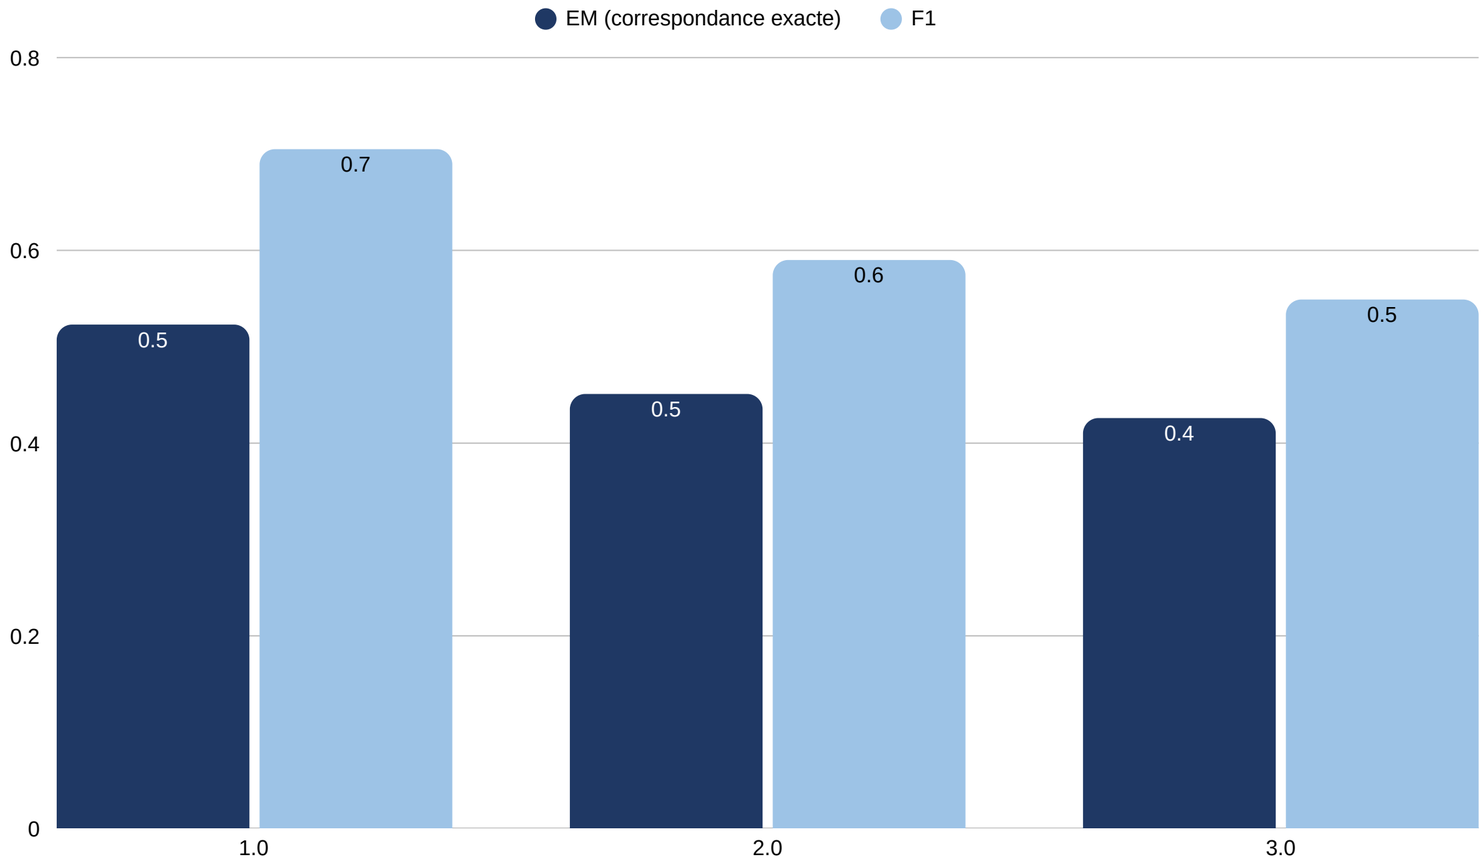
Un des K passages contient la réponse (BM25 R@5 = 0,929)

Pourquoi BM25 gagne

La documentation contient beaucoup de noms exacts (options, commandes)

BM25 est le meilleur retriever sur toutes les métriques

Évaluation complète (195 questions de test)



0,52

EM maximal, même avec le bon passage fourni

13 %

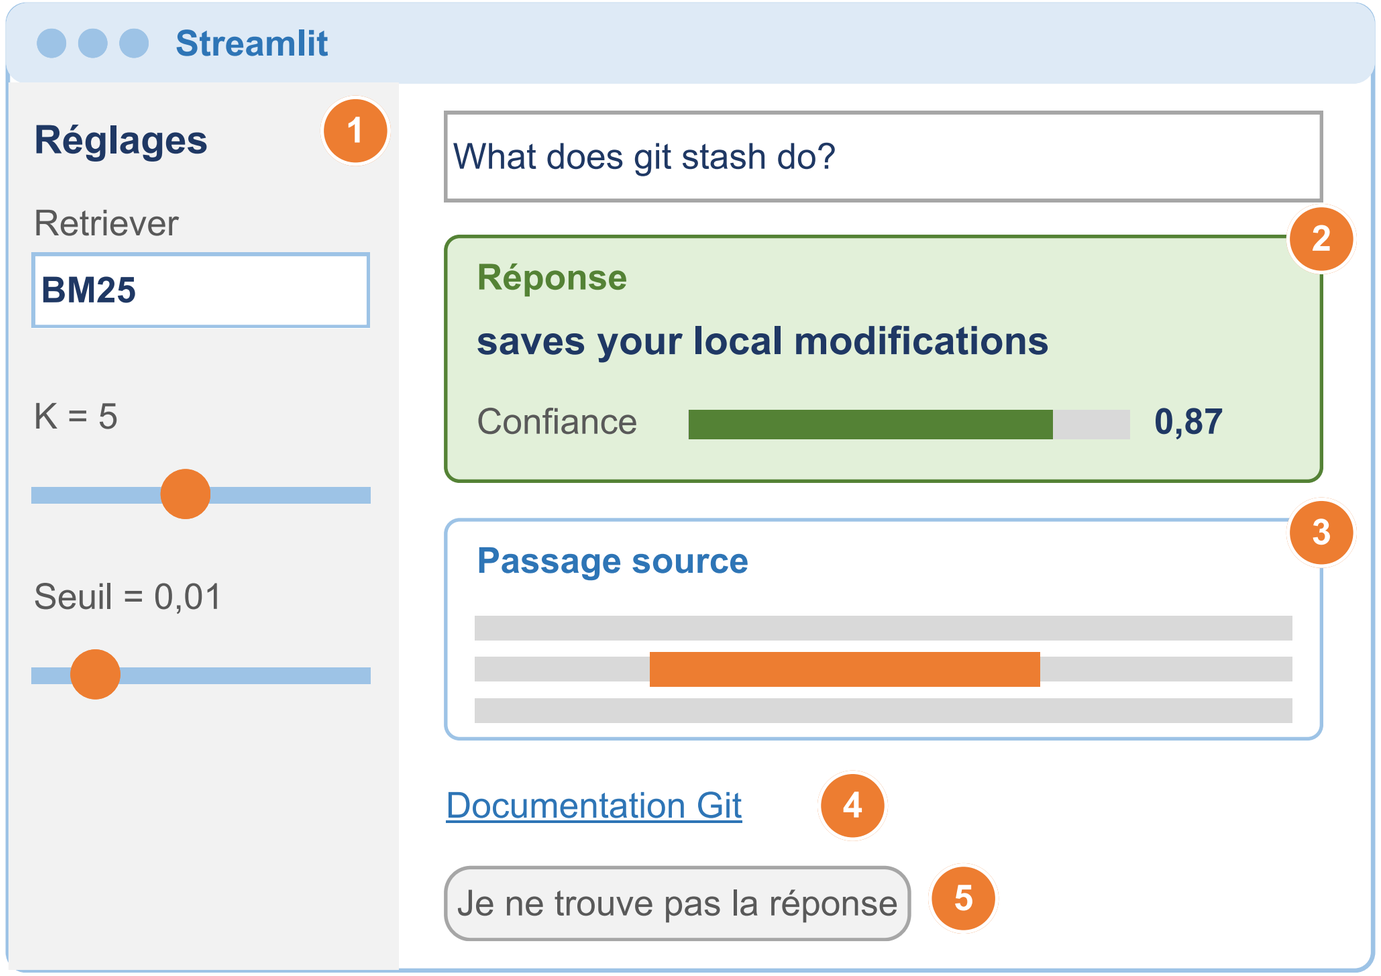
de questions où le système final refuse de répondre

± 7 points

d’incertitude sur 195 questions

Le goulot d’étranglement est le Reader, pas la recherche

Application : interface interactive



1. Réglages : retriever, K et seuil
2. Réponse affichée avec sa confiance
3. Passage source avec la réponse surlignée
4. Lien vers la page de documentation Git
5. « Je ne trouve pas la réponse » si la confiance est sous le seuil

Limites et analyse d’erreurs

± 7 pts

195 questions de test seulement : incertitude élevée

20

questions hors sujet pour régler le seuil, faciles à rejeter

Exemple d’erreur : « What does git pull do? »

Question
What does git pull do?

→

Filtre de navigation
retire le passage de description

→

Réponse erronée
vient de git-stash

Faiblesse : questions générales « What does X do? »

Conclusion et perspectives

Résultats

0,845 — R@5 : BM25 est le meilleur retriever

0,52 — EM : le Reader limite, même avec le bon passage

0,01 — Seuil : les questions hors sujet sont refusées

Perspectives

1. **Corriger le filtre de navigation**
2. **Ajouter un reranker**
3. **Tester des questions écrites par des humains**

Merci de votre attention!